

START ML


KARPOV.COURSES

ЛИНЕЙНЫЕ МОДЕЛИ

Пусть есть много наборов (x_i, y_i)

Причем о наших объектах нам известен исключительно один признак d_1

$$x_1 = d_1^1 = 3 \quad y_1 = 6$$




ЛИНЕЙНЫЕ МОДЕЛИ

Пусть есть много наборов (x_i, y_i)

Причем о наших объектах нам известен исключительно один признак d_1

$$x_1 = d_1^1 = 3 \quad y_1 = 6$$

$$x_2 = d_1^2 = 9 \quad y_2 = 8$$



ЛИНЕЙНЫЕ МОДЕЛИ

Пусть есть много наборов (x_i, y_i)


Причем о наших объектах нам известен исключительно один признак d_1

$$x_1 = d_1^1 = 3 \quad y_1 = 6$$

$$x_2 = d_1^2 = 9 \quad y_2 = 8$$

...

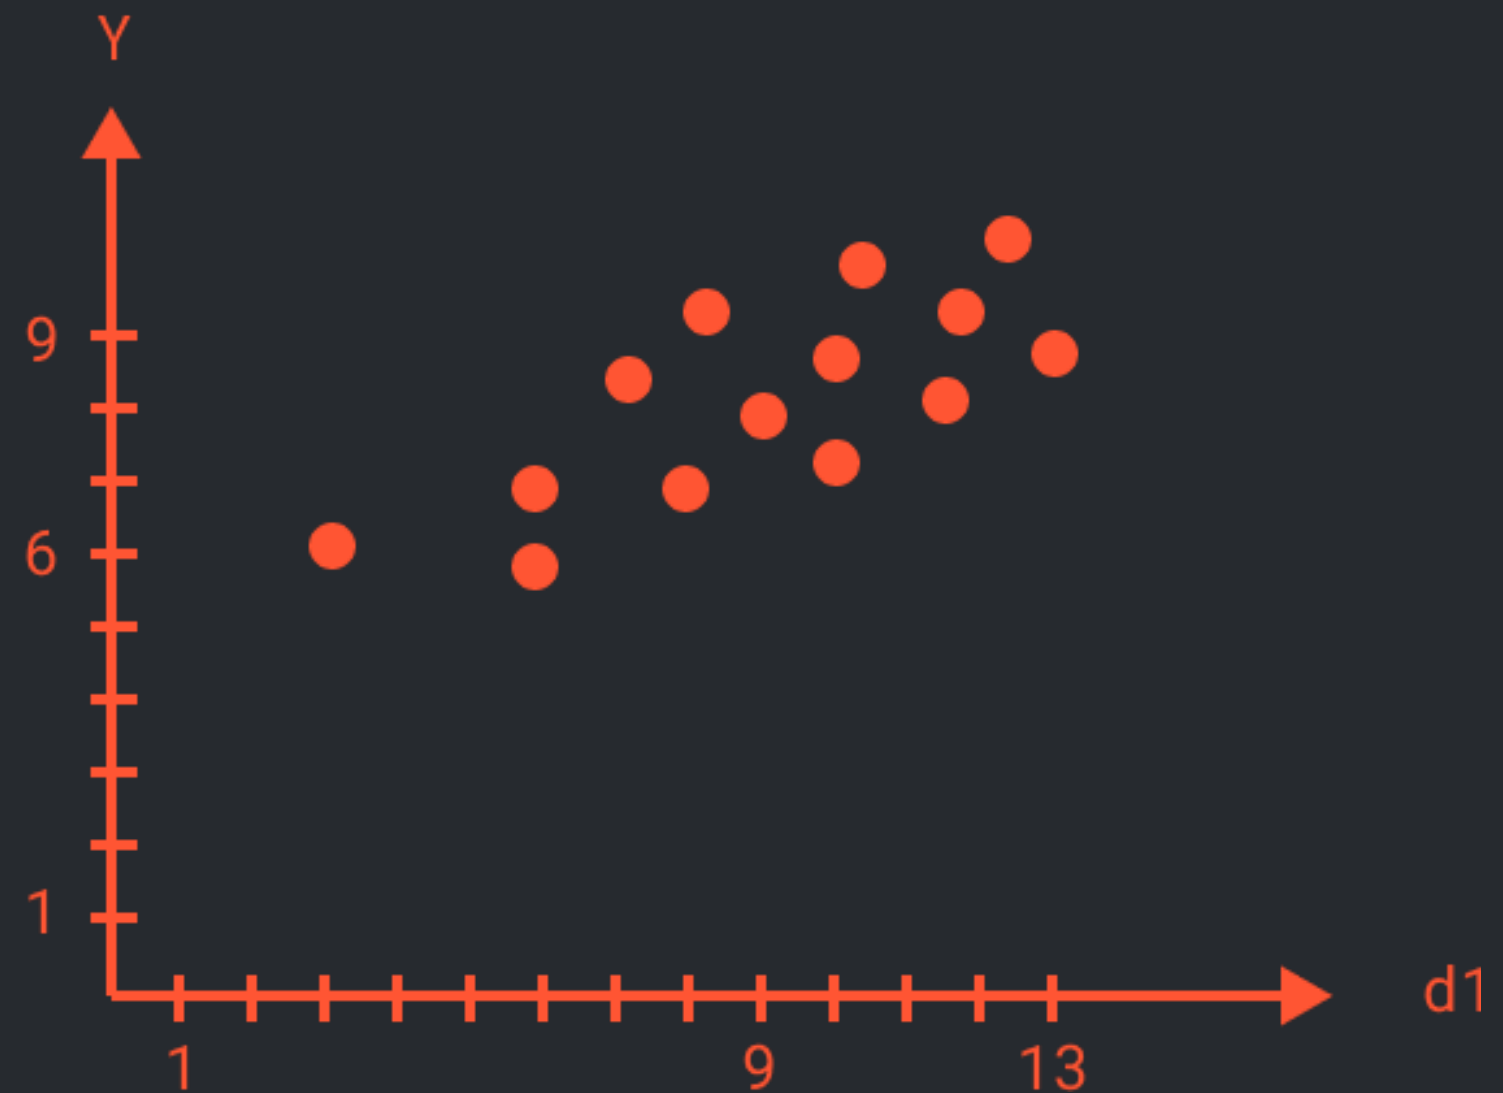
$$x_n = d_1^n = 13 \quad y_n = 9$$



ЛИНЕЙНЫЕ МОДЕЛИ

Построим нашу первую **линейную** модель!

$$a(x) = \beta_1 \cdot d_1$$




ЛИНЕЙНЫЕ МОДЕЛИ

Построим нашу первую **линейную** модель!

$$a(x) = \beta_1 \cdot d_1$$

$$a_1(x) = 0.5 \cdot d_1$$




ЛИНЕЙНЫЕ МОДЕЛИ

Построим нашу первую **линейную** модель!

$$a(x) = \beta_1 \cdot d_1$$

$$a_1(x) = 0.5 \cdot d_1$$

$$a_2(x) = 2 \cdot d_1$$



ЛИНЕЙНЫЕ МОДЕЛИ

Построим нашу первую **линейную** модель!

$$a(x) = \beta_1 \cdot d_1$$

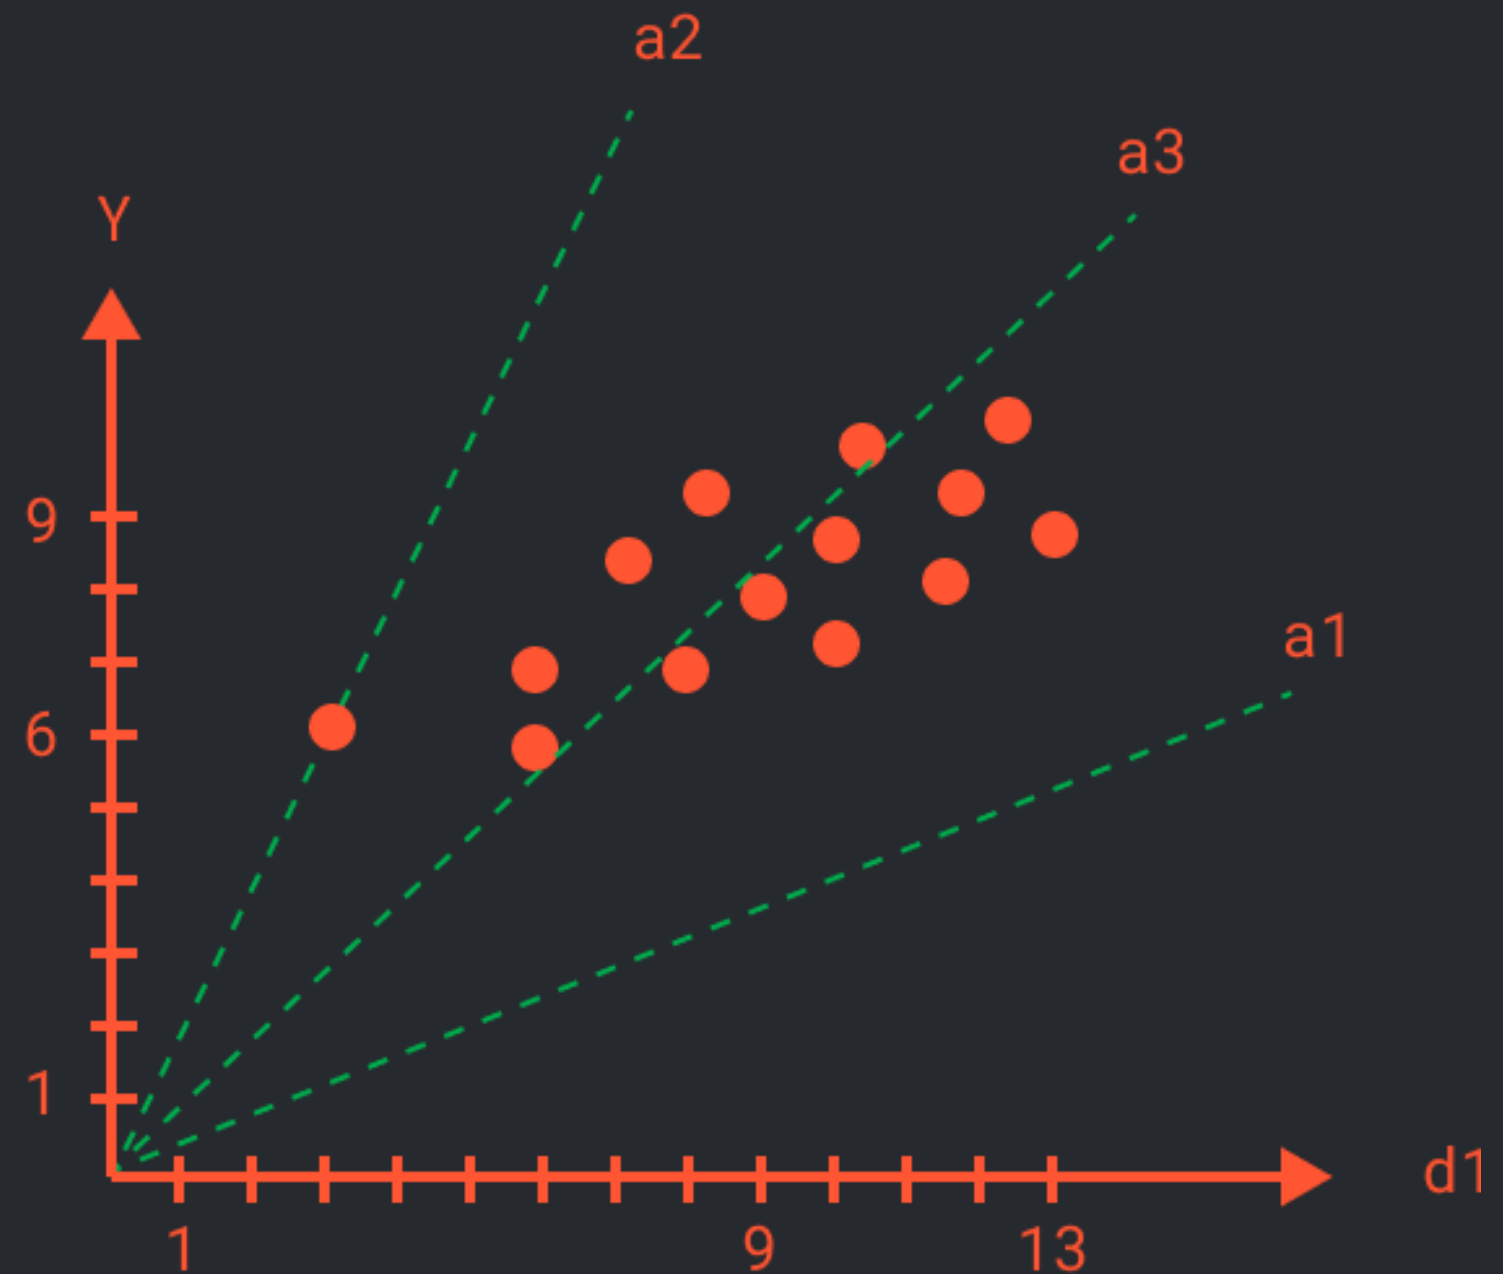
$$a_1(x) = 0.5 \cdot d_1$$

$$a_2(x) = 2 \cdot d_1$$

$$a_3(x) = 1 \cdot d_1$$

Это целое **семейство** моделей!

Линейных моделей.



ЛИНЕЙНЫЕ МОДЕЛИ

Обычно к линейному семейству принято добавлять **свободный коэффициент**

$$a(x) = \beta_1 \cdot d_1 + \beta_0$$


Это равносильно добавлению константного признака в объекты выборки

$$x_1 = (d_1^1, d_0) = (3, 1) \quad y_1 = 6$$

$$x_2 = (d_1^2, d_0) = (9, 1) \quad y_2 = 8$$

...

$$x_n = (d_1^n, d_0) = (13, 1) \quad y_n = 9$$



РЕЗЮМЕ

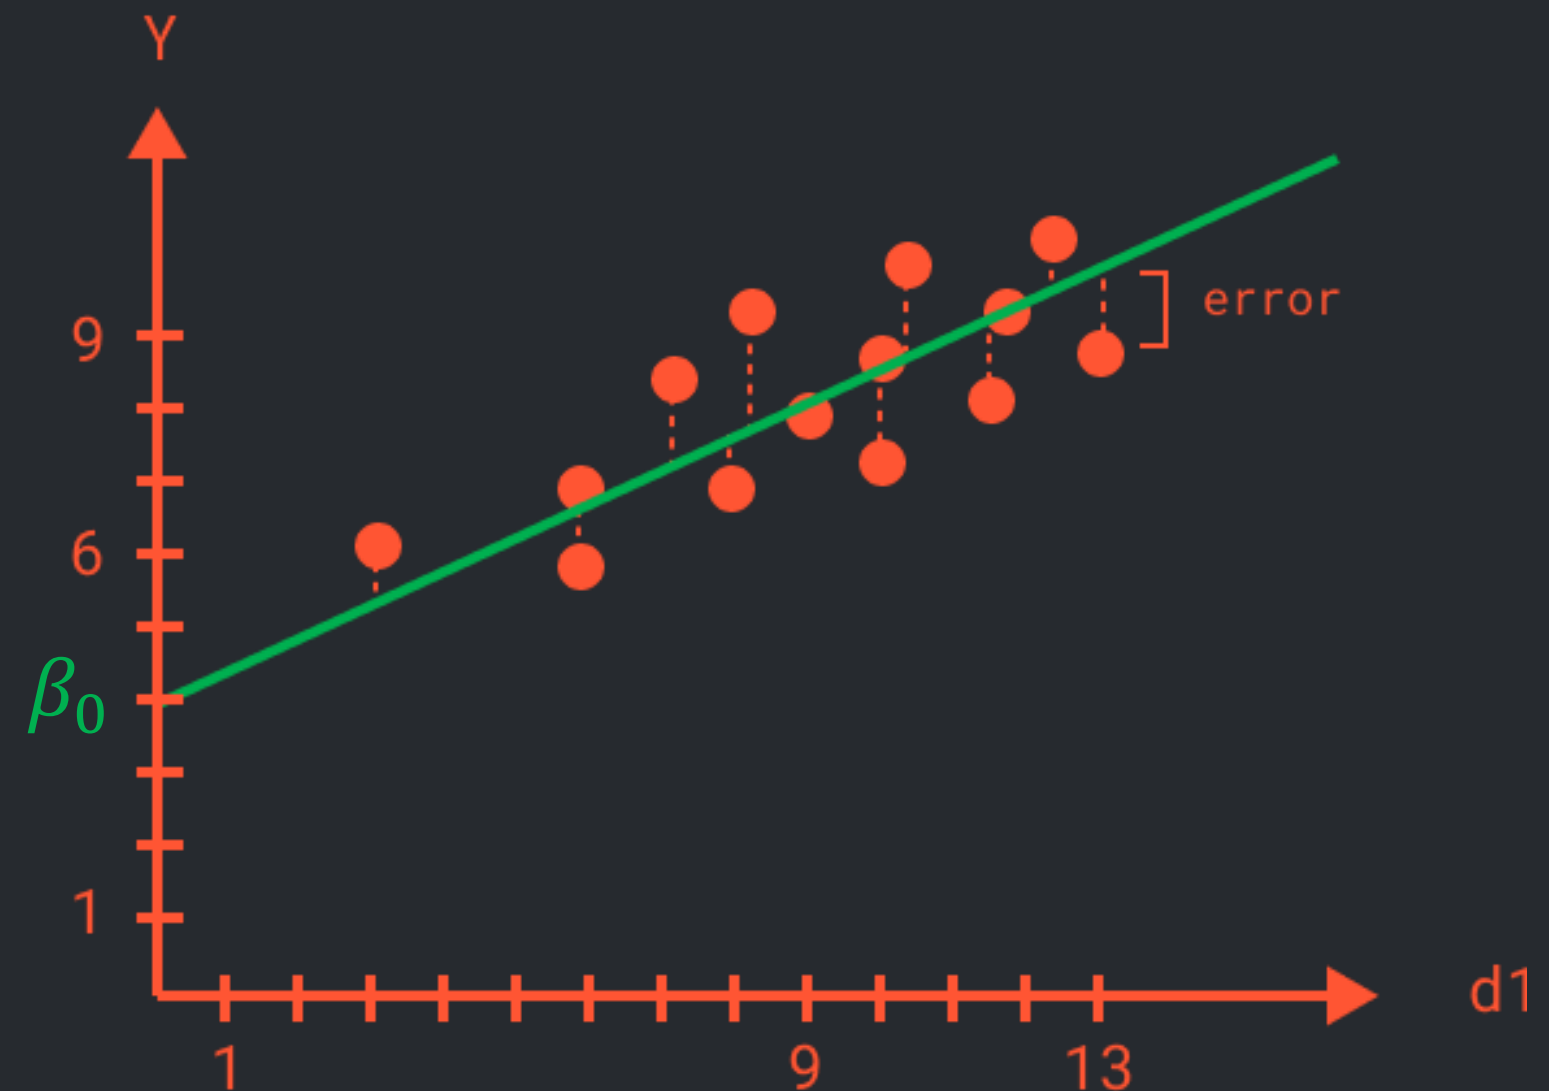
- Узнали, какие модели называют линейными (семейство)
- Чтобы получить конкретный алгоритм, следует подбирать параметры модели
- Стоит добавлять в линейные модели константный признак!

ЛИНЕЙНЫЕ МОДЕЛИ

МОДЕЛЬ

Обычно задача МО – это найти такие параметры в выбранном семействе, при которых зависимость между Y и X оценена наиболее правдоподобно.

При правильно выбранном Loss'e, это равносильно поиску минимума функционала качества.



$$\beta^* = \operatorname{argmin} Q(a(x), X)$$

МНОГОМЕРНАЯ ЛИНЕЙНАЯ РЕГРЕССИЯ

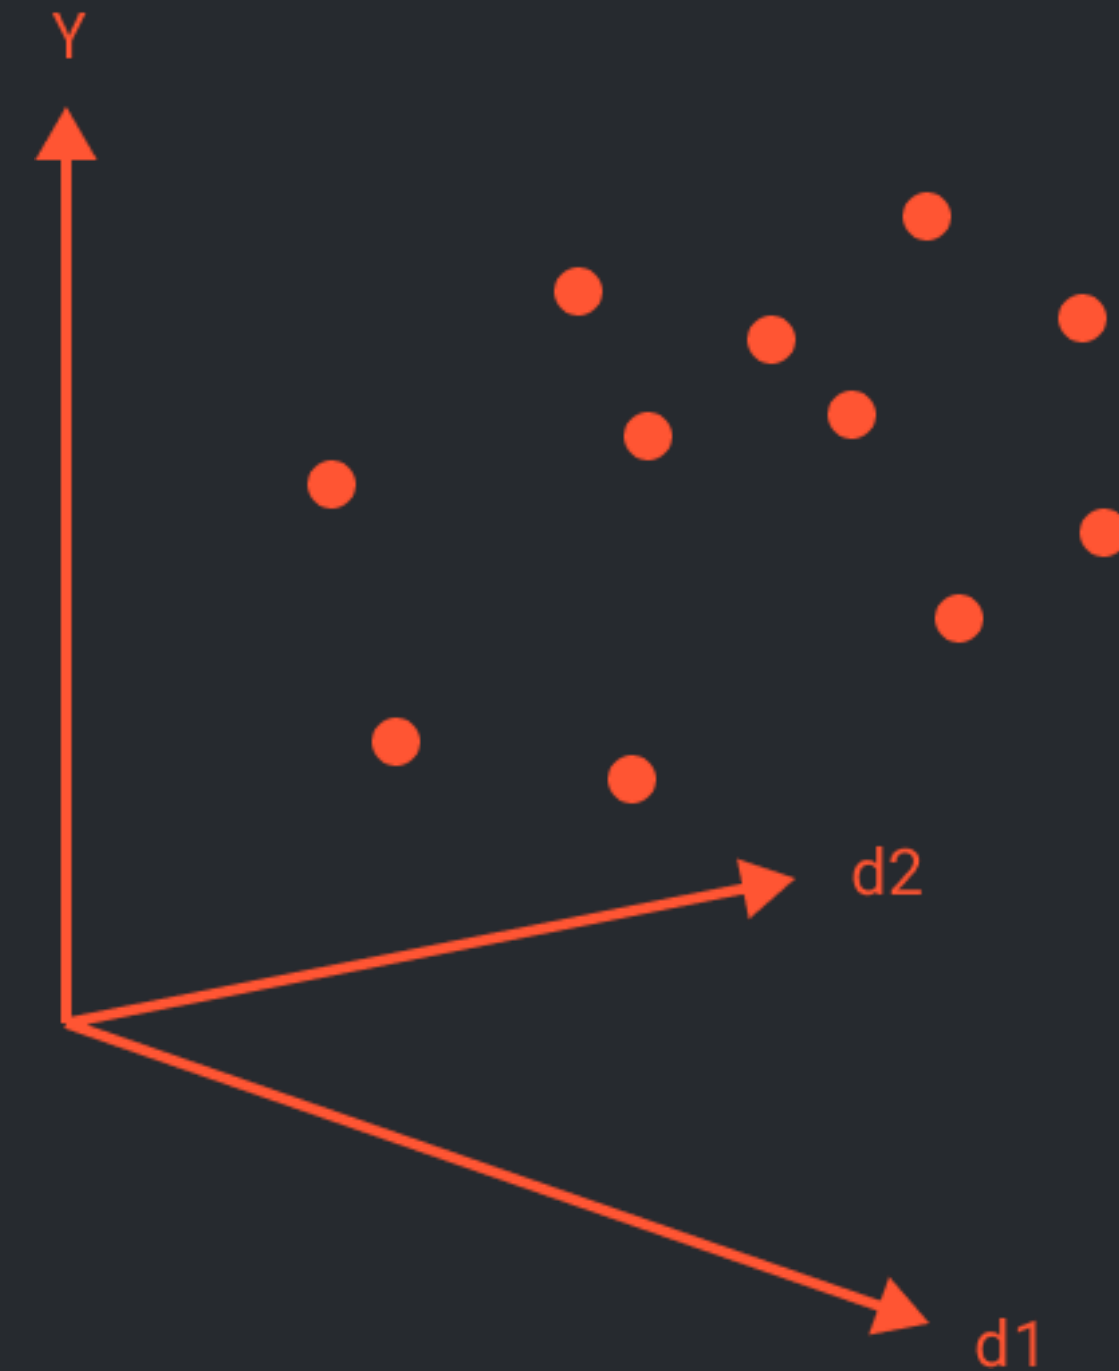
Теперь имеем набор объектов с 2 признаками

$$x_1 = (d_1^1, d_2^1) = (3, 2) \quad y_1 = 6$$

$$x_2 = (d_1^2, d_2^2) = (9, 5) \quad y_2 = 8$$

...

$$x_n = (d_1^n, d_2^n) = (13, 9) \quad y_n = 9$$




МНОГОМЕРНАЯ ЛИНЕЙНАЯ РЕГРЕССИЯ

Теперь строим не прямую, а плоскость!

$$a(x) = \beta_1 \cdot d_1 + \beta_2 \cdot d_2$$

$$a_1(x) = 0 \cdot d_1 + 0.2 \cdot d_2$$




МНОГОМЕРНАЯ ЛИНЕЙНАЯ РЕГРЕССИЯ

Теперь строим не прямую, а плоскость!

$$a(x) = \beta_1 \cdot d_1 + \beta_2 \cdot d_2$$

$$a_1(x) = 0 \cdot d_1 + 0.2 \cdot d_2$$

$$a_2(x) = 5 \cdot d_1 + 4 \cdot d_2$$



МНОГОМЕРНАЯ ЛИНЕЙНАЯ РЕГРЕССИЯ

Теперь строим не прямую, а плоскость!

$$a(x) = \beta_1 \cdot d_1 + \beta_2 \cdot d_2$$


$$a_1(x) = 0 \cdot d_1 + 0.2 \cdot d_2$$

$$a_2(x) = 5 \cdot d_1 + 4 \cdot d_2$$

$$a_3(x) = 2 \cdot d_1 + 3 \cdot d_2$$

Но еще лучше, если добавим константу!

$$a(x) = \beta_1 \cdot d_1 + \beta_2 \cdot d_2 + \beta_0$$



МНОГОМЕРНАЯ ЛИНЕЙНАЯ РЕГРЕССИЯ

Теперь строим не прямую, а плоскость!

$$a(x) = \beta_1 \cdot d_1 + \beta_2 \cdot d_2$$


$$a_1(x) = 0 \cdot d_1 + 0.2 \cdot d_2$$

$$a_2(x) = 5 \cdot d_1 + 4 \cdot d_2$$

Но еще лучше, если добавим константу!

$$a(x) = \beta_1 \cdot d_1 + \beta_2 \cdot d_2 + \beta_0$$

$$a_3(x) = 2 \cdot d_1 + 3 \cdot d_2 + 5$$



МНОГОМЕРНАЯ ЛИНЕЙНАЯ РЕГРЕССИЯ

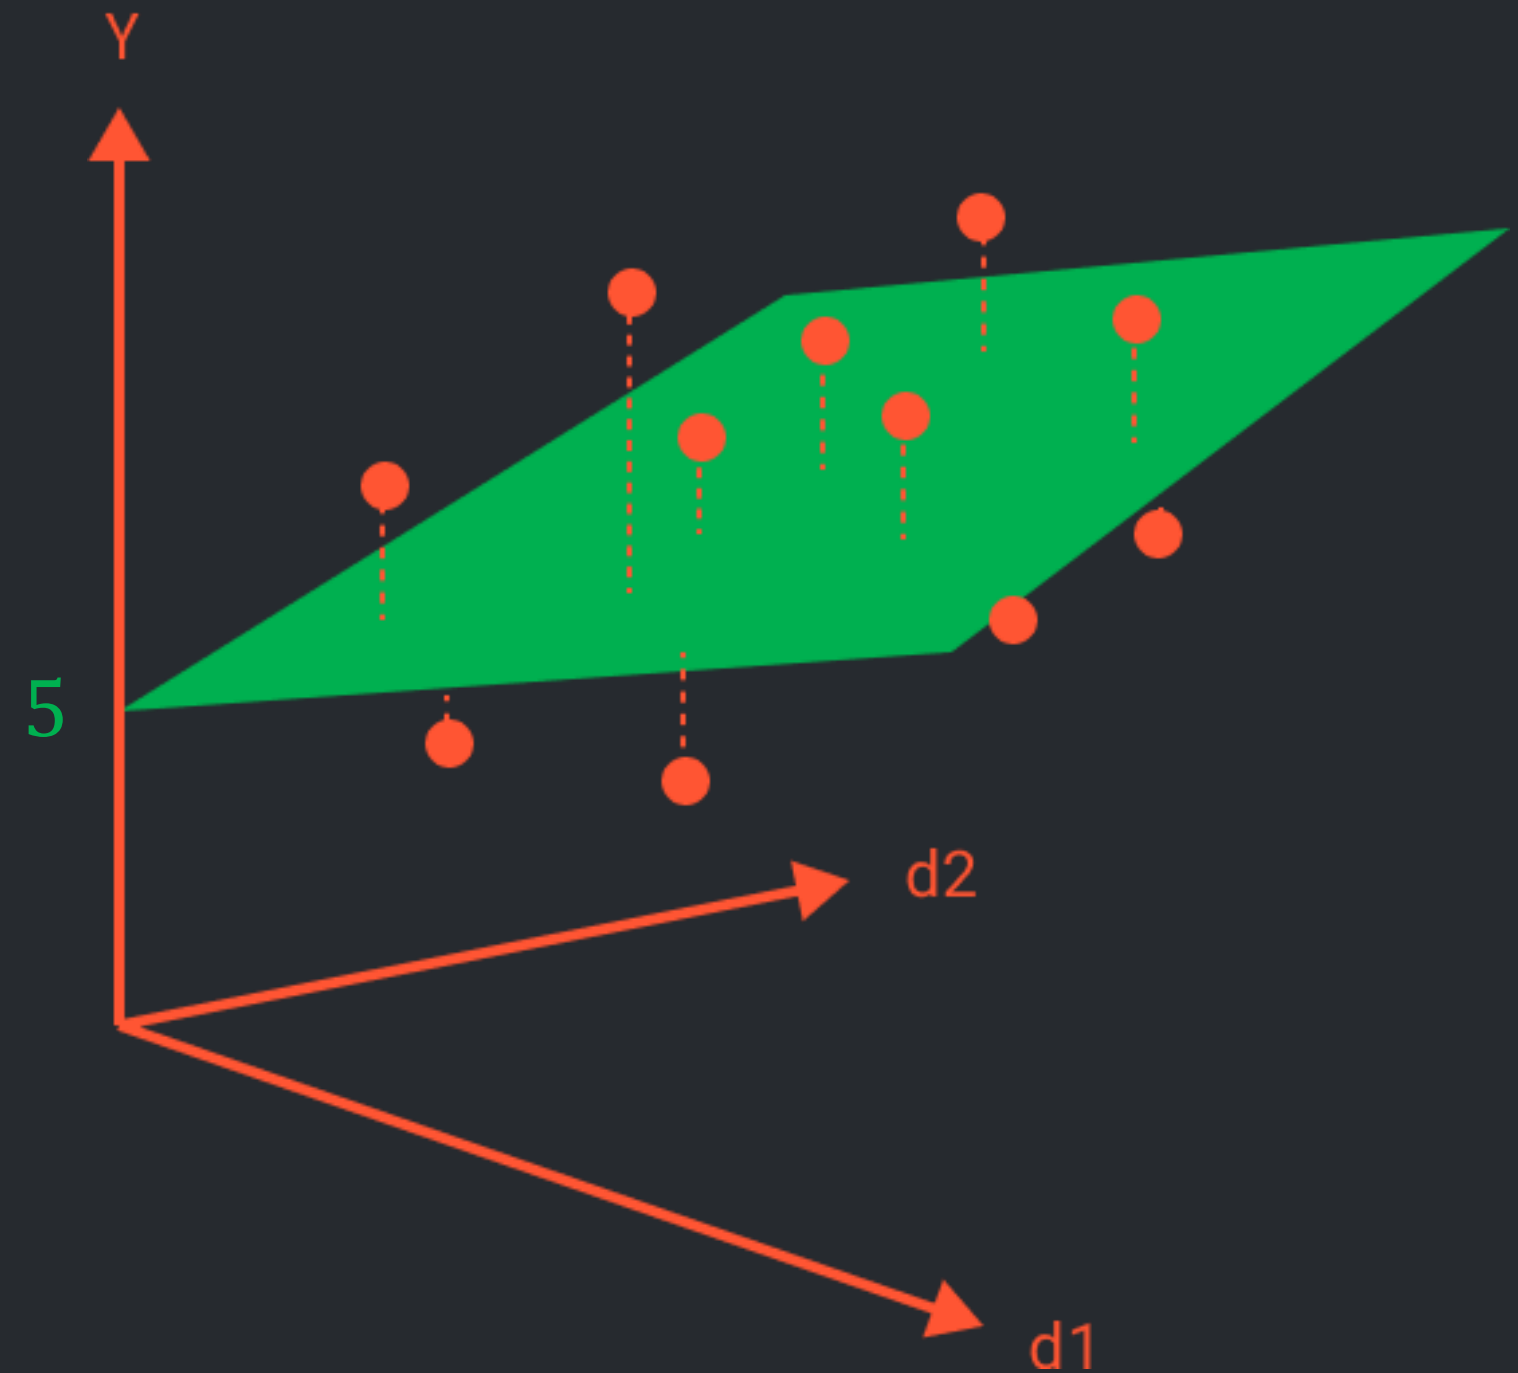
$$a(x) = \beta_1 \cdot d_1 + \beta_2 \cdot d_2 + \beta_0$$

$$a_3(x) = 2 \cdot d_1 + 3 \cdot d_2 + 5$$

$$\beta_1^* = 2 \quad \beta_2^* = 3 \quad \beta_0^* = 5$$

Лучшие параметры модели – те,
которые минимизируют функционал
ошибки!

$$\beta^* = \operatorname{argmin} Q(a(x), X)$$



ЛИНЕЙНАЯ РЕГРЕССИЯ OLS: ПРИМЕР

Найти лучшие β значит найти такие параметры, при которых $Q(a(x), X)$ минимальна.

Пусть попытаемся предсказать цену акции компаний в \$ через год по текущей цене (d^1) и сумме кредиторской задолженности в миллионах \$ (d^2) . Допустим, в выборку попало всего 3 компании (x_1, x_2, x_3) с соответствующими ответами (y_1, y_2, y_3) .

$$\begin{array}{c} x_1 \\ x_2 \\ x_3 \end{array} \begin{pmatrix} d_1 & d_2 \\ 23 & 0,5 \\ 35 & 1 \\ 18 & 0 \end{pmatrix} \quad \begin{array}{c} y_1 \\ y_2 \\ y_3 \end{array} \begin{pmatrix} 55 \\ 100 \\ 45 \end{pmatrix}$$

ЛИНЕЙНАЯ РЕГРЕССИЯ OLS: ПРИМЕР

Пока мы не знаем лучшие коэффициенты нашей линейной модели, но можем в общем виде для каждого объекта выписать нашу оценку в зависимости от β

Общее уравнение:

$$a(x) = \beta_1 \cdot d_1 + \beta_2 \cdot d_2 + \beta_0$$

Подставим первый объект:

$$a(x_1) = \beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0$$

Подставим второй объект:

$$a(x_2) = \beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0$$

Подставим третий объект:

$$a(x_3) = \beta_1 \cdot 18 + \beta_2 \cdot 0 + \beta_0$$

ЛИНЕЙНАЯ РЕГРЕССИЯ OLS: ПРИМЕР

Тогда можем и среднеквадратичное отклонение тоже записать, то есть наш функционал:

$$Q(a(x), X) = \frac{1}{m} \sum_i^m (a(x_i) - y_i)^2 =$$

$$\frac{1}{3} \cdot [(a(x_1) - y_1)^2 + (a(x_2) - y_2)^2 + (a(x_3) - y_3)^2] =$$

$$\frac{1}{3} \cdot [(\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55)^2 +$$

$$(\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100)^2 +$$

$$(\beta_1 \cdot 18 + \beta_0 - 45)^2]$$

$\rightarrow \min$

РЕЗЮМЕ

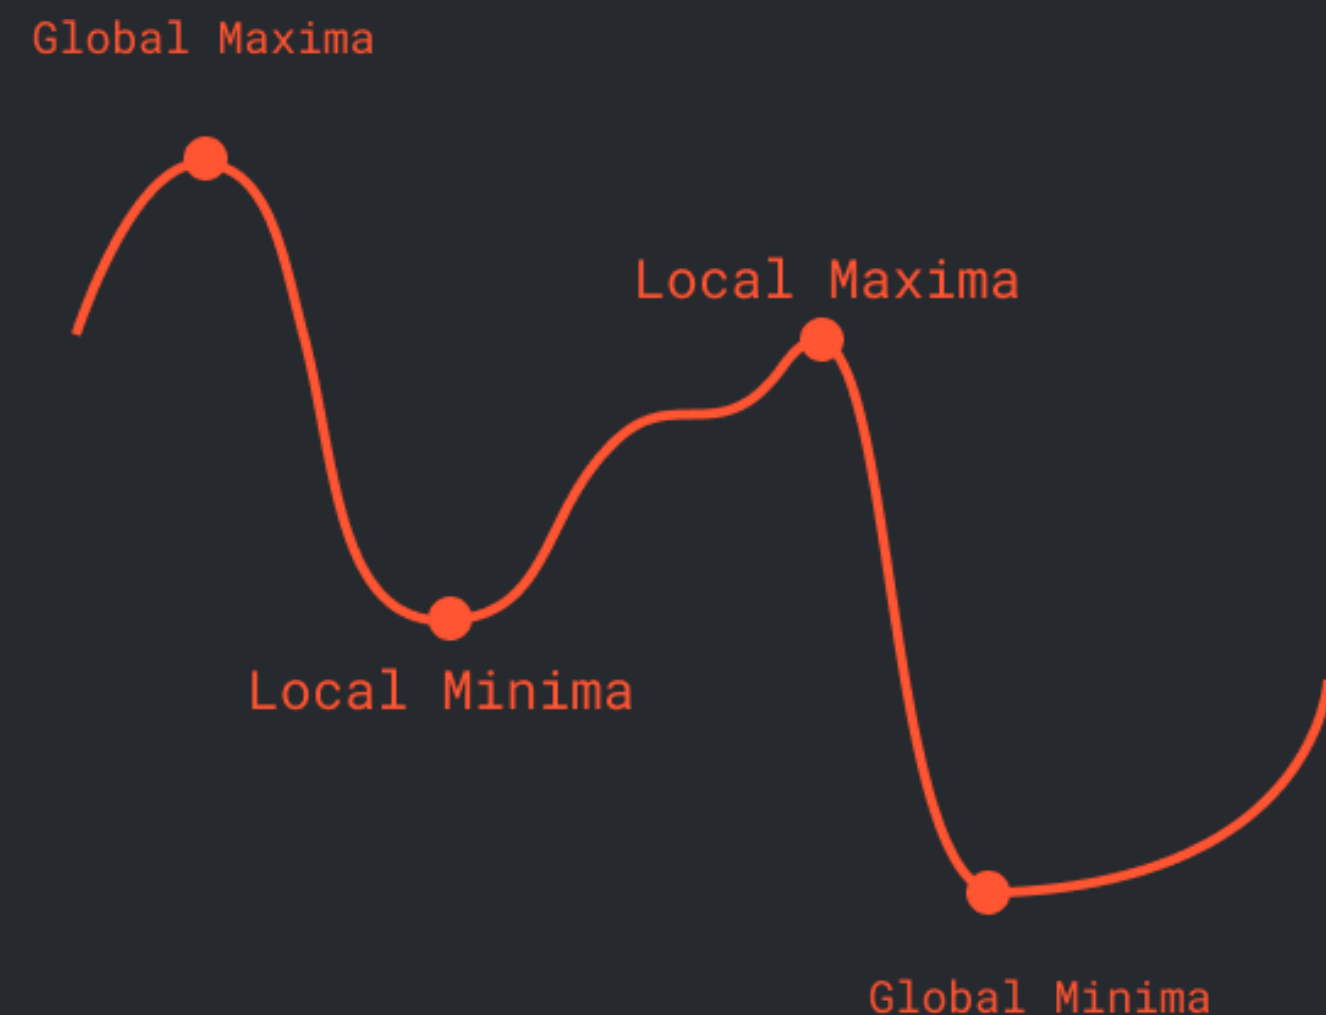
- Научились формально составлять задачу поиска оптимальных параметров регрессии
- Осталось научиться находить минимумы и максимумы математических функций!

ЛИКБЕЗ №2: ПРОИЗВОДНЫЕ И ЭКСТРЕМУМЫ

ПОИСК МИНИМУМОВ И МАКСИМУМОВ

Обратим внимание, что экстремумы (ямочки) возникают там, где функция меняет характер роста или убывания.

Круто было бы иметь инструмент, который в каждой точке показывал бы, убывает функция или растёт!




ЛИКБЕЗ №2: ПРОИЗВОДНЫЕ И ЭКСТРЕМУМЫ

ПОИСК МИНИМУМОВ И МАКСИМУМОВ

Обратим внимание, что экстремумы (ямочки) возникают там, где функция меняет характер роста или убывания.

Круто было бы иметь инструмент, который в каждой точке показывал бы, убывает функция или растёт!

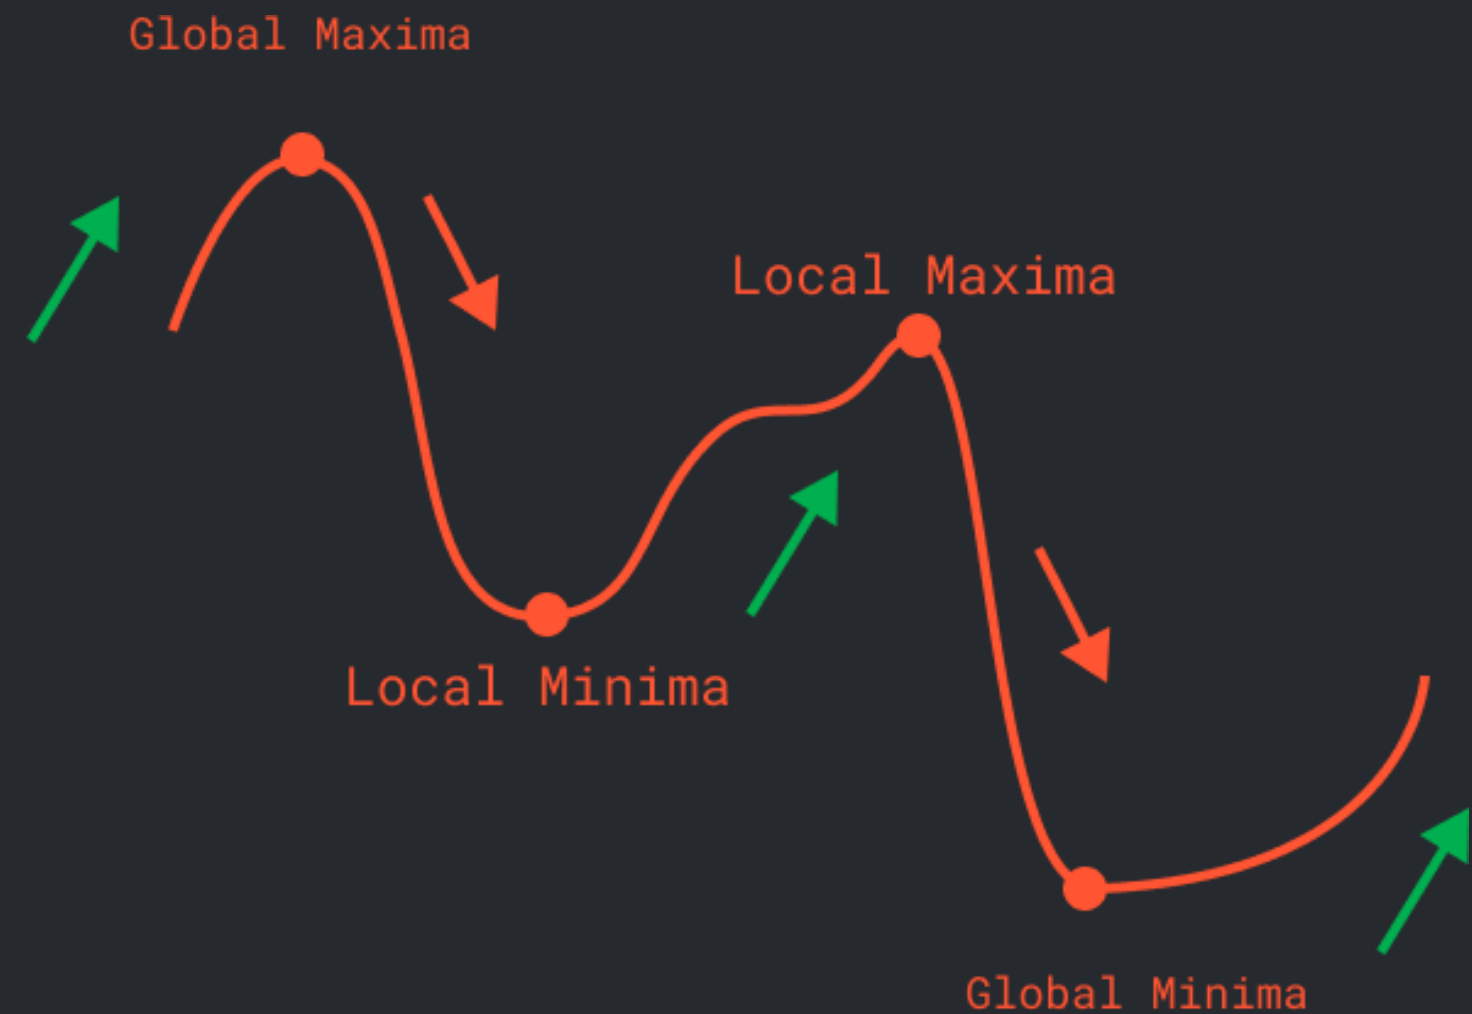


ЛИКБЕЗ №2: ПРОИЗВОДНЫЕ И ЭКСТРЕМУМЫ

ПРОИЗВОДНАЯ: y'_x

Производная показывает, в каком соотношении меняется значение функции, если совсем чуть-чуть изменить значение аргумента:

$$y'_x = \frac{\Delta y}{\Delta x} \quad \Delta x \approx 0$$




ЛИКБЕЗ №2: ПРОИЗВОДНЫЕ И ЭКСТРЕМУМЫ

ПРОИЗВОДНАЯ: y'_x

$y'_x > 0 \rightarrow$ функция растет!

$y'_x < 0 \rightarrow$ функция убывает!

$y'_x = 0 \rightarrow$ интересная точка!



ЛИКБЕЗ №2: ПРОИЗВОДНЫЕ И ЭКСТРЕМУМЫ

КАК СЧИТАТЬ ПРОИЗВОДНЫЕ?

$$y'_x = \frac{\Delta y}{\Delta x}$$

$$\frac{\Delta y}{\Delta x} = \frac{y(x + \Delta x) - y(x)}{\Delta x}$$

$$P.S. \quad \Delta x \rightarrow 0$$

Пусть $y(x) = x^2$

$$y'_x = \frac{(x + \Delta x)^2 - x^2}{\Delta x} = \frac{x^2 + 2 \cdot x \cdot \Delta x + (\Delta x)^2 - x^2}{\Delta x} =$$

$$\frac{2 \cdot x \cdot \Delta x + (\Delta x)^2}{\Delta x} = \frac{2 \cdot x \cdot \Delta x}{\Delta x} + \frac{(\Delta x)^2}{\Delta x} = 2 \cdot x + \Delta x = 2 \cdot x$$

ЛИКБЕЗ №2: ПРОИЗВОДНЫЕ И ЭКСТРЕМУМЫ

ТАБЛИЦА ПРОИЗВОДНЫХ

$$(x^n)' = n \cdot x^{n-1}$$

$$(a^x)' = a^x \cdot \ln(a)$$

$$(\log_a x)' = \frac{1}{x \cdot \ln a}$$

$$(\sin x)' = \cos x$$

$$(\sin x)' = \cos x$$

$$(\cos x)' = -\sin x$$

$$(\operatorname{tg} x)' = \frac{1}{\cos^2 x}$$

$$(\operatorname{ctg} x)' = -\frac{1}{\sin^2 x}$$

$$(\arcsin x)' = \frac{1}{\sqrt{1-x^2}}$$

$$(\arccos x)' = \frac{-1}{\sqrt{1-x^2}}$$

$$(\operatorname{arctg} x)' = \frac{1}{1+x^2}$$

$$(\operatorname{arcctg} x)' = \frac{-1}{1+x^2}$$

ЛИКБЕЗ №2: ПРОИЗВОДНЫЕ И ЭКСТРЕМУМЫ

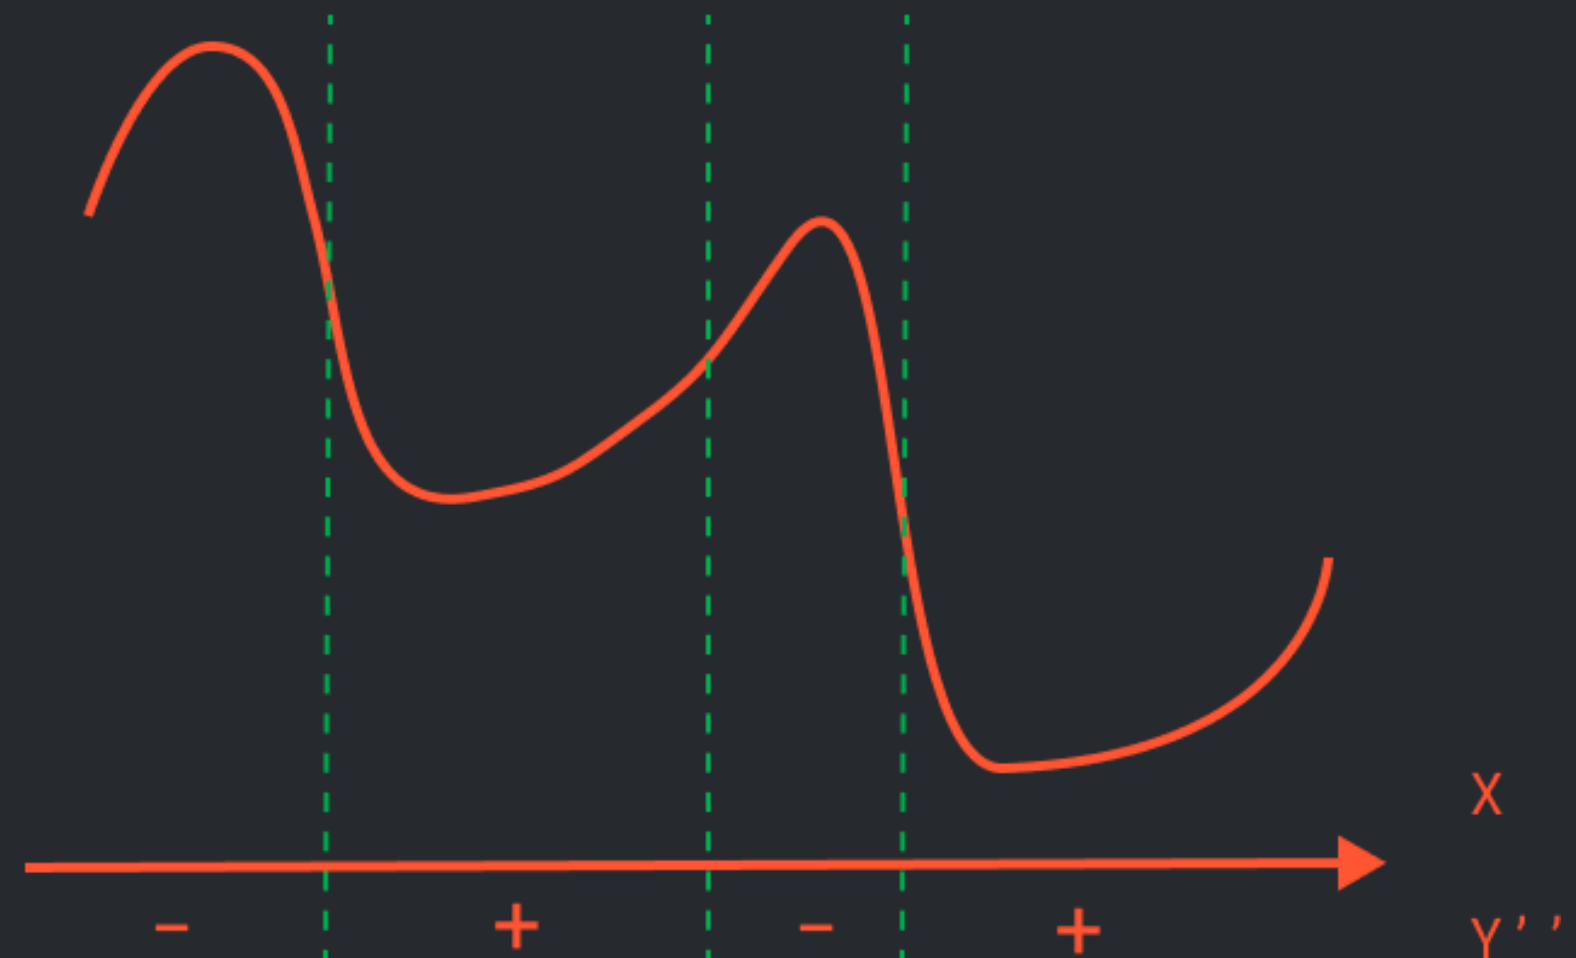
УСЛОВИЕ ВТОРОГО ПОРЯДКА

Заметим, чтобы различить минимумы и максимумы между собой, должно выполняться соответственно условие выпуклости / вогнутости – за это отвечает вторая производная.

$$y'' = (y')'$$

$$y'' = y' > 0 \rightarrow \text{функция выпуклая}$$


$$y'' = y' < 0 \rightarrow \text{функция вогнутая}$$



ЛИКБЕЗ №2: ПРОИЗВОДНЫЕ И ЭКСТРЕМУМЫ

$$y = x^3 - 6x^2 - 15x + 10$$

$$\begin{aligned} y' &= (x^3 - 6x^2 - 15x + 10)' = \\ (x^3)' - 6 \cdot (x^2)' - 15 \cdot (x)' + (10)' &= \\ 3x^2 - 12x - 15 &= 0 \end{aligned}$$



$$y'(-2) = 3 \cdot (-2)^2 - 12 \cdot (-2) - 15 = 21 > 0$$


$$y'(0) = 0 - 0 - 15 = -15 < 0$$

$$y'(6) = 3 \cdot (6)^2 - 12 \cdot 6 - 15 = 21 > 0$$

$$y'' = (3x^2 - 12x - 15)' = 6x - 12$$

$$y''(-1) = -18 < 0 \Rightarrow \text{это локальный максимум}$$

$$y''(5) = +18 > 0 \Rightarrow \text{это локальный минимум}$$



ЛИКБЕЗ №2: ПРОИЗВОДНЫЕ И ЭКСТРЕМУМЫ

ФУНКЦИИ НЕСКОЛЬКИХ ПЕРЕМЕННЫХ

Логика та же самая – чтобы найти критические точки, приравниваем первые производные к 0, решаем систему.

$$z(x; y) = x^2 + 3y^2$$

$$\begin{cases} z'_x = 2 \cdot x = 0 \\ z'_y = 6 \cdot y = 0 \end{cases} \rightarrow (x^*, y^*) = (0; 0)$$

УСЛОВИЕ ВТОРОГО ПОРЯДКА

Чтобы проверить выпуклость / вогнутость в окрестности критической точки, применяем критерий Сильвестра на матрицу из частных производных 2 порядка.

$$z''_{xx} = (z'_x)'_x = 2$$

$$z''_{xy} = (z'_x)'_y = 0$$

$$z''_{yx} = (z'_y)'_x = 0$$

$$z''_{yy} = (z'_y)'_y = 6$$

$$H_z(x^*; y^*) = \begin{pmatrix} 2 & 0 \\ 0 & 6 \end{pmatrix}$$

РЕЗЮМЕ

- Выяснили, что такое производная и о чем она сигнализирует
- Научились выводить и находить производные различных функций
- На примере посмотрели, как можно исследовать функцию на экстремумы
- Узнали про условие второго порядка
- Масштабировали знания на функции нескольких переменных

ЛИНЕЙНАЯ РЕГРЕССИЯ OLS: ПРИМЕР

$$Q = \frac{1}{3} \cdot [(\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55)^2 + (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100)^2 + (\beta_1 \cdot 18 + \beta_0 - 45)^2] \rightarrow \min$$

$$\left\{ \begin{array}{l} Q'_{\beta_1} = \frac{1}{3} \cdot [23 \cdot 2 \cdot (\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55) + 35 \cdot 2 \cdot (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100) + 18 \cdot 2 \cdot (\beta_1 \cdot 18 + \beta_0 - 45)] = 0 \\ Q'_{\beta_2} = \frac{1}{3} \cdot [0.5 \cdot 2 \cdot (\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55) + 1 \cdot 2 \cdot (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100)] = 0 \\ Q'_{\beta_0} = \frac{1}{3} \cdot [1 \cdot 2 \cdot (\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55) + 1 \cdot 2 \cdot (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100) + 1 \cdot 2 \cdot (\beta_1 \cdot 18 + \beta_0 - 45)] = 0 \end{array} \right.$$

$$(\beta_1^*, \beta_2^*, \beta_0^*) = (5, -30, -45)$$

Выпуклость очевидна из формы функционала. Но можно и вправду проверить еще и матрицу Гессе.

Итого, лучшая линейная модель для нашей выборки:

$$a(x) = 5 \cdot d_1 - 30 \cdot d_2 - 45$$

ЛИНЕЙНАЯ РЕГРЕССИЯ OLS: ПРИМЕР

$$Q = \frac{1}{3} \cdot [(\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55)^2 + (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100)^2 + (\beta_1 \cdot 18 + \beta_0 - 45)^2] \rightarrow \min$$

$$\left\{ \begin{aligned} Q'_{\beta_1} &= \frac{1}{3} \cdot [23 \cdot 2 \cdot (\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55) + 35 \cdot 2 \cdot (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100) + 18 \cdot 2 \cdot (\beta_1 \cdot 18 + \beta_0 - 45)] = 0 \\ Q'_{\beta_2} &= \frac{1}{3} \cdot [0.5 \cdot 2 \cdot (\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55) + 1 \cdot 2 \cdot (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100)] = 0 \\ Q'_{\beta_0} &= \frac{1}{3} \cdot [1 \cdot 2 \cdot (\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55) + 1 \cdot 2 \cdot (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100) + 1 \cdot 2 \cdot (\beta_1 \cdot 18 + \beta_0 - 45)] = 0 \end{aligned} \right.$$

$$(\beta_1^*, \beta_2^*, \beta_0^*) = (5, -30, -45)$$

Выпуклость очевидна из формы функционала. Но можно и вправду проверить еще и матрицу Гессе.

Итого, лучшая линейная модель для нашей выборки:

$$a(x) = 5 \cdot d_1 - 30 \cdot d_2 - 45$$

ЛИНЕЙНАЯ РЕГРЕССИЯ OLS: ПРИМЕР

$$Q = \frac{1}{3} \cdot [(\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55)^2 + (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100)^2 + (\beta_1 \cdot 18 + \beta_0 - 45)^2] \rightarrow \min$$

$$\left\{ \begin{array}{l} Q'_{\beta_1} = \frac{1}{3} \cdot [23 \cdot 2 \cdot (\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55) + 35 \cdot 2 \cdot (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100) + 18 \cdot 2 \cdot (\beta_1 \cdot 18 + \beta_0 - 45)] = 0 \\ Q'_{\beta_2} = \frac{1}{3} \cdot [0.5 \cdot 2 \cdot (\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55) + 1 \cdot 2 \cdot (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100)] = 0 \\ Q'_{\beta_0} = \frac{1}{3} \cdot [1 \cdot 2 \cdot (\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55) + 1 \cdot 2 \cdot (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100) + 1 \cdot 2 \cdot (\beta_1 \cdot 18 + \beta_0 - 45)] = 0 \end{array} \right.$$

	d_1	d_2	
x_1	23	0,5	y_1
x_2	35	1	y_2
x_3	18	0	y_3

ЛИКБЕЗ №3: МАТРИЦЫ

Матрицы – форма хранения чисел в математике! Бывают разных размеров.
Матрицы с 1 строкой или 1 столбцом часто называют векторами.

$$\begin{pmatrix} 23 & 0,5 \\ 35 & 1 \\ 18 & 0 \end{pmatrix}$$

3 x 2

$$\begin{pmatrix} 55 \\ 100 \\ 45 \end{pmatrix}$$

3 x 1

ЛИКБЕЗ №3: МАТРИЧНОЕ СЛОЖЕНИЕ / ВЫЧИТАНИЕ

Складывать и вычитать можно ИСКЛЮЧИТЕЛЬНО матрицы одного размера!

Делается это поэлементно!

$$\begin{pmatrix} 23 & 0,5 \\ 35 & 1 \\ 18 & 0 \end{pmatrix} + \begin{pmatrix} 30 & 0 \\ 40 & 3 \\ 10 & 0 \end{pmatrix} = \begin{pmatrix} 53 & 0,5 \\ 75 & 4 \\ 28 & 0 \end{pmatrix}$$

3×2 3×2 3×2

ЛИКБЕЗ №3: МАТРИЧНОЕ УМНОЖЕНИЕ

Определено матричное умножение $A \cdot B$, если A – размера $n \times k$, B – размера $k \times m$. Причем тогда результат умножения этих двух матриц – матрица C – размера $n \times m$. Причем чтобы получить c_{ij} , нужно скалярно перемножить i строку A и j столбец B . Например,

$$\begin{array}{c} A \\ \begin{pmatrix} 23 & 0,5 \\ 35 & 1 \\ 18 & 0 \end{pmatrix} \\ 3 \times 2 \end{array} \begin{array}{c} B \\ \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} \\ 2 \times 1 \end{array} = \begin{array}{c} C \\ \begin{pmatrix} 23 \cdot \beta_1 + 0,5 \cdot \beta_2 \\ 35 \cdot \beta_1 + 1 \cdot \beta_2 \\ 18 \cdot \beta_1 + 0 \cdot \beta_2 \end{pmatrix} \\ 3 \times 1 \end{array}$$

ЛИКБЕЗ №3: ТРАНСПОНИРОВАНИЕ МАТРИЦЫ

Транспонировать матрицу – повернуть ее на бок, т.е. столбцы превратить в строки и наоборот.

$$\begin{matrix} & A \\ \begin{pmatrix} 23 & 0,5 \\ 35 & 1 \\ 18 & 0 \end{pmatrix} \\ 3 \times 2 \end{matrix}$$

T
 \rightarrow

$$\begin{matrix} & A^T \\ \begin{pmatrix} 23 & 35 & 18 \\ 0,5 & 1 & 0 \end{pmatrix} \\ 2 \times 3 \end{matrix}$$

ЛИКБЕЗ №3: ЕДИНИЧНАЯ МАТРИЦА

Ее принято обозначать символом E . Она может быть любого квадратного размера. Аналог 1.

$$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

ЛИКБЕЗ №3: ОБРАТНЫЕ МАТРИЦЫ

Обратная матрица – это некоторый многомерный аналог обратному числу. Точнее, говорят, что у матрицы A существует единственная обратная к ней матрица A^{-1} , если

$$A \cdot A^{-1} = E.$$

$$\begin{matrix} A \\ \begin{pmatrix} 2 & 5 \\ 3 & 8 \end{pmatrix} \end{matrix} \begin{matrix} A^{-1} \\ \begin{pmatrix} 8 & -5 \\ -3 & 2 \end{pmatrix} \end{matrix} = \begin{matrix} E \\ \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \end{matrix}$$

ЛИНЕЙНАЯ РЕГРЕССИЯ OLS: МАТРИЧНАЯ ФОРМА

Вспомним, что всю нашу выборку, состоящую из ряда объектов и признаков можно представить в виде матрицы X размера n х k , где n – количество элементов в выборке, а k – количество признаков (включая константу). Введем вектор коэффициентов B и заметим, что:

$$(X \cdot B - Y)^T (X \cdot B - Y) \cdot \frac{1}{n} = Q$$

Проверим это на нашем предыдущем примере

ЛИНЕЙНАЯ РЕГРЕССИЯ OLS: МАТРИЧНАЯ ФОРМА

$$\frac{1}{3} \cdot \left(\begin{bmatrix} 23 & 0,5 & 1 \\ 35 & 1 & 1 \\ 18 & 0 & 1 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_0 \end{bmatrix} - \begin{bmatrix} 55 \\ 100 \\ 45 \end{bmatrix} \right)^T \cdot \left(\begin{bmatrix} 23 & 0,5 & 1 \\ 35 & 1 & 1 \\ 18 & 0 & 1 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_0 \end{bmatrix} - \begin{bmatrix} 55 \\ 100 \\ 45 \end{bmatrix} \right) =$$

$$\frac{1}{3} \cdot \left(\begin{bmatrix} 23 \cdot \beta_1 + 0,5 \cdot \beta_2 + \beta_0 \\ 35 \cdot \beta_1 + \beta_2 + \beta_0 \\ 18 \cdot \beta_1 + \beta_0 \end{bmatrix} - \begin{bmatrix} 55 \\ 100 \\ 45 \end{bmatrix} \right)^T \cdot \left(\begin{bmatrix} 23 \cdot \beta_1 + 0,5 \cdot \beta_2 + \beta_0 \\ 35 \cdot \beta_1 + \beta_2 + \beta_0 \\ 18 \cdot \beta_1 + \beta_0 \end{bmatrix} - \begin{bmatrix} 55 \\ 100 \\ 45 \end{bmatrix} \right) =$$

$$\frac{1}{3} \cdot \left(\begin{bmatrix} 23 \cdot \beta_1 + 0,5 \cdot \beta_2 + \beta_0 - 55 \\ 35 \cdot \beta_1 + \beta_2 + \beta_0 - 100 \\ 18 \cdot \beta_1 + \beta_0 - 45 \end{bmatrix} \right)^T \cdot \left(\begin{bmatrix} 23 \cdot \beta_1 + 0,5 \cdot \beta_2 + \beta_0 - 55 \\ 35 \cdot \beta_1 + \beta_2 + \beta_0 - 100 \\ 18 \cdot \beta_1 + \beta_0 - 45 \end{bmatrix} \right) =$$

$$\frac{1}{3} \cdot [(\beta_1 \cdot 23 + \beta_2 \cdot 0.5 + \beta_0 - 55)^2 + (\beta_1 \cdot 35 + \beta_2 \cdot 1 + \beta_0 - 100)^2 + (\beta_1 \cdot 18 + \beta_0 - 45)^2]$$

ЛИНЕЙНАЯ РЕГРЕССИЯ OLS: МАТРИЧНАЯ ФОРМА

Тогда задача поиска оптимальных коэффициентов сводится к минимизации произведения двух матриц. Можно взять матричный дифференциал и приравнять его к нулю. Этот шаг аналогичен нахождению частных производных и решению системы для поиска критических точек.

$$Q = \frac{1}{n} \cdot (X \cdot B - Y)^T (X \cdot B - Y) \rightarrow \min$$

$$dQ(\beta^*) = 0$$

$$\beta^* = \begin{bmatrix} \beta_1^* \\ \beta_2^* \\ \beta_0^* \end{bmatrix} = (X^T \cdot X)^{-1} \cdot X^T \cdot Y = \begin{bmatrix} +5 \\ -30 \\ -45 \end{bmatrix}$$

РЕЗЮМЕ

- Изучили матричный аппарат
- Нашли на примере оптимальные коэффициенты регрессии
- Перевели задачу минимизации среднеквадратической ошибки на язык матриц
- Пора практиковаться!

СПАСИБО

ТАБАКАЕВ НИКИТА